

Module Project

RAG (Retrieval-Augmented Generation) sử dụng Streamlit

Đinh Nhật Thành

Ngày 4 tháng 7 năm 2025

Mục lục

1	Giải thích thuật ngữ	2
2	Mở Đầu	2
1	Mô tả bài toán	2
2	Nội dung bài viết	2
3	LangChain framework cho xây dựng hệ thống RAG	3
1	Các thành phần cốt lõi của RAG	3
2	Vấn đề tồn tại khi xây dựng mô hình RAG (không dùng framework)	4
3	Giải pháp mà LangChain đưa ra	5
4	Giải thích căn bản về các syntax của LangChain	6
5	Giải pháp của LangChain cho từng vấn đề tồn tại của RAG	10
4	Demo kết quả mô hình RAG cơ bản	10
5	Cải Thiện Mô hình RAG	10
1	Prompting có cấu trúc (Structured Prompting)	10
2	Các kiểu Prompt khác nhau	10
3	Cải tiến tốc độ truy vấn sử dụng FAISS	10
6	Tổng kết	10
7	Kết Thúc	10
A	Phụ lục giải thích thuật ngữ	11

Giải thích thuật ngữ

Khi trong bài có từ ngữ chuyên ngành khó hiểu, Ta có thể xem giải thích chi tiết một số thuật ngữ quan trọng dưới đây:

- **Parse (Phân tích cú pháp):** Là quá trình chuyển chuỗi ký tự thành cấu trúc dữ liệu. [Parse \(Phụ lục\)](#)
- **Protocol (Giao thức):** Tập hợp quy tắc giao tiếp giữa các hệ thống. [Protocol \(Phụ lục\)](#)
- **Synchronous vs. Asynchronous:** Liên quan đến thời điểm thực hiện tác vụ. [Synchronous Asynchronous \(Phụ lục\)](#)

Mở Đầu


1 Mô tả bài toán

Trong kỷ nguyên của mô hình ngôn ngữ lớn (LLM), việc xây dựng hệ thống hỏi–đáp thông minh từ tài liệu cá nhân hoặc doanh nghiệp đang trở nên phổ biến. Tuy nhiên, các LLM như GPT-4 hay Gemini vốn không có quyền truy cập trực tiếp vào tài liệu riêng lẻ (như notes học tập, báo cáo tuần, hợp đồng nội bộ, v.v.). Điều này dẫn đến nhu cầu xây dựng các hệ thống truy hồi kết hợp sinh (Retrieval-Augmented Generation – RAG), giúp LLM “nhớ” đúng những gì người dùng cung cấp.

2 Nội dung bài viết

Trong bài viết này, chúng ta xây dựng một Web App đơn giản, sử dụng **Streamlit**, 1 thư viện giúp xây dựng UI 1 cách nhanh chóng và mô hình **RAG**, 1 kỹ thuật xử lý ngôn ngữ cho phép người dùng hỏi đáp dựa trên nội dung từ các Notes (ví dụ: `M1W1_Wednesday.pdf`) thuộc chương trình học **AIO Conquer 2025**. Các bước thực hiện bao gồm:

- Người dùng tải tài liệu PDF lên giao diện Streamlit.
- Hệ thống sử dụng `PyPDFLoader` để phân tích nội dung văn bản.
- Văn bản được chia nhỏ thành các đoạn (chunk) khoảng 500 tokens bằng `SemanticChunker`.
- Mỗi đoạn được mã hoá thành vector bằng `HuggingFaceEmbeddings`, lưu trong vector DB Chroma.
- Khi người dùng đặt câu hỏi, hệ thống truy hồi các đoạn liên quan, kết hợp vào một prompt, rồi gửi đến LLM để sinh ra câu trả lời phù hợp theo ngữ cảnh.



Hình 1: Luồng dữ liệu và thành phần chính của ứng dụng RAG trên Streamlit

Nội dung bài viết không chỉ dừng lại ở việc xây dựng ứng dụng, mà còn tập trung vào việc giải thích tổng quan mô hình RAG – các thành phần cốt lõi, những khó khăn khi xây dựng RAG bằng công cụ cơ bản, và vì sao cần một framework như LangChain để đơn giản hóa và chuẩn hóa quy trình.

Mục tiêu bài viết là giúp người đọc – đặc biệt là người mới bắt đầu – tiếp cận RAG một cách căn bản, có hệ thống, dựa trên tư duy *First Principle Thinking*: bắt đầu từ bài toán thực tế, xác định vấn đề tồn tại, rồi từng bước đi đến giải pháp tối ưu với LangChain.

LangChain framework cho xây dựng hệ thống RAG

1 Các thành phần cốt lõi của RAG

Để hiểu vì sao LangChain lại hữu ích trong việc xây dựng hệ thống RAG, trước tiên ta cần nắm rõ các thành phần cốt lõi của mô hình này.

- **Retrieval** (Truy hồi): Sau khi người dùng hoàn tất việc tải tài liệu lên Vector Database và bắt đầu hỏi. RAG sẽ truy vấn các đoạn văn bản liên quan nhất tới câu hỏi sử dụng thông tin của văn bản được [Embedding](#) trong Vector Database.
- **Augmentation** (Tăng cường ngữ cảnh): Giúp mô hình LLM hiểu hơn về ngữ cảnh bằng cách kết hợp các đoạn text được truy hồi trong bước Retrieval, ví dụ đầu ra hoặc yêu cầu đi kèm người dùng muốn vào prompt.
- **Generation** (Sinh ngôn ngữ): Mô hình ngôn ngữ lớn (LLM) nhận prompt có kèm ngữ cảnh trong bước Augmentation và sinh ra câu trả lời.

Tại sao dùng RAG? Cho phép câu trả lời được **dựa trên dữ liệu thực tế**, giảm **hallucination** và hỗ trợ **cập nhật thông tin mới** mà không cần fine-tuning lại toàn bộ mô hình.

Một hệ thống RAG cơ bản thường bao gồm:

1. **Text Loader**: trích xuất văn bản từ các nguồn như PDF, TXT, DOCX, v.v.

2. **Text Splitter:** chia nhỏ văn bản thành các đoạn ngắn, không quá dài để phù hợp với giới hạn đầu vào của mô hình.
3. **Embedding Model:** mã hóa mỗi đoạn thành vector bằng mô hình học máy (vd: all-MiniLM, Instructor, v.v.).
4. **Vector Database:** lưu trữ các vector để có thể truy hồi nhanh những đoạn gần nhất với câu hỏi.
5. **Retriever:** tìm các đoạn liên quan nhất dựa trên câu hỏi của người dùng.
6. **Prompt + LLM:** ghép các đoạn được tìm thấy vào một mẫu prompt, rồi gửi đến mô hình ngôn ngữ để tạo câu trả lời.

2 Vấn đề tồn tại khi xây dựng mô hình RAG (không dùng framework)

Mặc dù ý tưởng của RAG khá đơn giản, nhưng nếu Ta là người mới và tự xây dựng hệ thống từ đầu, Ta sẽ gặp nhiều khó khăn. Dưới đây là các vấn đề phổ biến mà nhiều người mới gặp phải:

1. Thiếu chuẩn hóa quy trình:

- Không có "hướng đi rõ ràng" nên dễ bị lạc giữa việc: nên xử lý văn bản trước hay làm embedding trước? Nên lưu vector ở đâu?
- Dễ viết code rời rạc, khó kiểm soát pipeline tổng thể.

2. Lỗi khi kết nối các bước thủ công:

- Mỗi bước (load → split → embed → lưu → truy vấn → prompt → gọi LLM) cần thư viện riêng.
- Ví dụ: dùng PyPDF2 để load, sentence_transformers để embed, FAISS để lưu vector → khó đồng bộ.
- Việc truyền dữ liệu giữa các bước cũng dễ bị lỗi do định dạng không đồng nhất.

3. Viết prompt thủ công tốn thời gian:

- Ta phải tự viết prompt để đảm bảo LLM hiểu ngữ cảnh, tránh trả lời ngoài lề.
- Khi tăng số đoạn truy hồi, prompt cũng phải được chỉnh lại — dễ gây lỗi hoặc rối logic.

4. Khó mở rộng hoặc tái sử dụng pipeline:

- Nếu Ta muốn thay thế embedding model, hoặc chuyển từ Chroma sang FAISS, Ta phải chỉnh lại nhiều đoạn code.
- Việc tái sử dụng workflow trong project khác gần như phải viết lại từ đầu.

5. Không dễ chạy song song hoặc debug từng bước:

- Ta không thể theo dõi đầu ra từng bước (ví dụ sau khi chunk, sau khi embed, sau khi truy hồi).
- Khi có lỗi (ví dụ truy hồi sai đoạn), khó biết nguyên nhân nằm ở bước nào.

3 Giải pháp mà LangChain đưa ra

Một trong những điểm mạnh nổi bật của LangChain là việc xây dựng mỗi thành phần trong RAG thành một **Modular Component** – nghĩa là mỗi bước như:

- Tải tài liệu (DocumentLoader)
- Chia nhỏ văn bản (TextSplitter)
- Mã hoá thành vector (Embeddings)
- Lưu trữ/truy vấn (VectorStore, Retriever)
- Khai báo LLM (LLM)
- Tạo sinh câu trả lời sử dụng LLM (LLMChain)

đều được đóng gói dưới dạng một Class riêng biệt. Điều này mang lại 3 lợi ích quan trọng:

- **Tái sử dụng:** Dễ tái sử dụng từng thành phần trong nhiều ứng dụng khác nhau.
- **Kiểm thử dễ dàng:** Có thể test từng bước độc lập (vd: kiểm tra chỉ TextSplitter hoặc Retriever).
- **Thay thế linh hoạt:** Chỉ cần thay 1 class là có thể chuyển từ mô hình OpenAI sang HuggingFace hoặc thay FAISS bằng Chroma mà không ảnh hưởng toàn bộ hệ thống.

Ngoài ra LangChain đơn giản hóa và tối ưu quy trình xây dựng hệ thống bằng cách sử dụng 1 lớp xây dựng gọi là **Runnable: lớp bao bọc (wrapper)** Thay vì chỉ viết các hàm thủ công như Python thông thường, LangChain sử dụng Object Runnable như một lớp bao (wrapper) giúp Ta:

- Biến mọi thao tác (dù đơn giản như một hàm ‘lambda’) thành một “khối logic” có thể:
 - chạy độc lập, (‘RunnableLambda’)
 - xâu chuỗi các hàm sử dụng RunnableSequence sử dụng ký hiệu (‘|’), nó hoạt động tương tự như Pipe trong UnixLinux. (ví dụ: func1 | func2)
 - chạy song song (‘RunnableMap’) cho phép xử lý các hàm 1 cách **đồng bộ (synchronous)** hoặc **bất đồng bộ (asynchronous)** mà Ta không cần viết thêm logic phức tạp.
- Việc đối gộp các hàm như 1 khối logic, cho phép người phát triển tư duy theo luồng (pipeline) rõ ràng.

Khác với cách viết hàm truyền thống, Runnable giống như “*block LEGO thông minh*”: dễ lắp, dễ thay, dễ mở rộng. Ngoài ra, Ta cũng có thể xem thêm phần giải thích về [synchronous](#) và [asynchronous](#) trong phụ lục để hiểu rõ vì sao việc chuyển đổi giữa 2 kiểu thực thi này là quan trọng trong xây dựng ứng dụng quy mô lớn.

Ví dụ:

```
1 # Hàm truyền thống
2 def upper(text):
3     return text.upper()
4
5 # Hàm gói LangChain Runnable
6 from langchain.schema.runnable import RunnableLambda
7
8 runnable_upper = RunnableLambda(lambda x: x.upper())
9 runnable_upper.invoke("langchain") # Output: LANGCHAIN
```

Listing 1: So sánh cách viết thường vs dùng Runnable trong LangChain

Tuy đoạn code nhìn có vẻ dài hơn, nhưng khi ta muốn kết hợp nhiều bước thành pipeline, chạy đồng thời trên nhiều input, hoặc debugging từng bước giữa chain, thì hệ thống ‘Runnable’ trở thành công cụ cực kỳ hữu ích và dễ mở rộng.

Hỗ trợ sẵn hàng chục thư viện phổ biến:

- Ví dụ: Ta có thể dùng FAISS, Chroma, Weaviate,... chỉ với vài dòng code thay vì cấu hình thủ công.
- Tương tự với OpenAI, HuggingFace, Claude, v.v.

Tối ưu khả năng mở rộng: Ta có thể mở rộng từ một ứng dụng RAG đơn giản sang hệ thống đa tác nhân, phân nhánh, tích hợp phản hồi người dùng (feedback loop) mà không phải viết lại toàn bộ code.

Tích hợp dễ dàng với các framework UI như Streamlit, Gradio: Ta có thể kết nối backend LangChain với frontend dễ dàng qua API hoặc trực tiếp embed trong app Streamlit.

Tóm lại: LangChain không phải là công cụ “thay thế” các thư viện cơ bản, mà là framework kết nối chúng theo một cách mạch lạc, mở rộng được, và giúp Ta tập trung vào logic thay vì xử lý từng bước nhỏ. Nhờ đó, chỉ với 5–10 dòng code Ta đã có được full RAG pipeline, dễ maintain và mở rộng thêm tính năng (chaining, branching, agents...).

4 Giải thích các syntax cơ bản của LangChain

Trong LangChain, các **Runnable** là những khối xây dựng cơ bản, mỗi Runnable đại diện cho một tác vụ hoặc hoạt động đơn lẻ. Về bản chất, một Runnable là một đối tượng Python được thiết kế để tối ưu hóa hàm của Ta bằng cách sử dụng tính song song.

Khái niệm chính về Runnables trong LangChain

- **Tính mô đun (Modularity):**

Mỗi Runnable là một khối xây dựng đại diện cho một nhiệm vụ hoặc thao tác đơn lẻ. Các nhiệm vụ này có thể bao gồm chạy một LLM (Mô hình Ngôn ngữ Lớn), xử lý dữ liệu hoặc xử chuỗi nhiều hoạt động lại với nhau.

- **Tính kết hợp (Composability):**

Nhiều Runnable có thể được liên kết với nhau để hình thành một chuỗi (pipeline). Điều này cho phép xây dựng các quy trình làm việc phức tạp từ các thành phần nhỏ hơn, có thể tái sử dụng.

- **Tính tái sử dụng (Reusability):**

Các Runnable có thể được tái sử dụng trong các quy trình làm việc khác nhau.

- **Thực thi bất đồng bộ (Asynchronous Execution):**

Các Runnable có khả năng thực hiện các tác vụ một cách song song, tăng hiệu suất cho các ứng dụng.

Các thành phần API cốt lõi

1. Runnable: Lớp cơ sở (Object)

Runnable là lớp cơ sở cho tất cả các thành phần có thể thực thi trong LangChain. Ta có thể kế thừa từ lớp này để tạo các thao tác tùy chỉnh của mình.

```

1 from langchain.schema.runnable import Runnable
2
3 class MyRunnable(Runnable):
4     def invoke(self, input):
5         return input.upper()
6
7 # Tạo một thể hiện của MyRunnable
8 runnable = MyRunnable()
9
10 # Kiểm tra với một input mẫu
11 result = runnable.invoke("hello world")
12 print(result) # Output: HELLO WORLD
13
14 # Với một ví dụ khác
15 result = runnable.invoke("LangChain is awesome")
16 print(result) # Output: LANGCHAIN IS AWESOME
17

```

Listing 2: Ví dụ về Runnable cơ bản

2. RunnableMap:

Tương tự như hàm map() trong Python, RunnableMap thực thi nhiều Runnable bên trong nó một cách song song và tổng hợp kết quả của chúng. Điều này hữu ích khi Ta muốn áp dụng nhiều hàm độc lập cho một chuỗi đầu vào và nhận các kết quả khác nhau cho từng hàm.

```

1 from langchain.schema.runnable import RunnableMap
2
3 runnable_map = RunnableMap({
4     "uppercase": lambda x: x.upper(),
5     "reverse": lambda x: x[::-1],
6 })
7
8 result = runnable_map.invoke("langchain")
9 # Output: {'uppercase': 'LANGCHAIN', 'reverse': 'niahcnaL'}
10

```

Listing 3: Ví dụ về RunnableMap

3. RunnableSequence:

`RunnableSequence` áp dụng từng `Runnable` một cách tuần tự vào đầu vào. Đơn giản hơn `RunnableMap`, đầu vào được xử lý tuyến tính qua từng `Runnable`.

```
1 from langchain.schema.runnable import RunnableSequence
2
3 runnable_sequence = RunnableSequence([
4     lambda x: x.lower(),
5     lambda x: x[::-1],
6 ])
7
8 result = runnable_sequence.invoke("LangChain")
9 # Output: 'niahcnag'
10
```

Listing 4: Ví dụ về `RunnableSequence`

4. `RunnableLambda`:

`RunnableLambda` là `Runnable` đơn giản nhất, về cơ bản là định nghĩa một hàm lambda làm `Runnable`. Nó áp dụng một hàm duy nhất cho chuỗi đầu vào.

```
1 from langchain.schema.runnable import RunnableLambda
2
3 uppercase_runnable = RunnableLambda(lambda x: x.upper())
4 result = uppercase_runnable.invoke("langchain")
5 # Output: 'LANGCHAIN'
6
```

Listing 5: Ví dụ về `RunnableLambda`

Ví dụ: Hướng tư duy cho bài toán phân biệt cảm xúc sử dụng LangChain

Bài toán: Xử lý phản hồi của khách hàng, phân loại cảm xúc và tóm tắt nó.

1. Đầu tiên mình cần tạo 1 hàm để phân loại cảm xúc (nếu "good" thì là Positive, ngược lại là Negative). Vì đây là 1 hàm độc lập, mình có thể sử dụng RunnableLambda.
2. Bước tiếp theo là truy xuất ngữ cảnh, sau đó cung cấp hướng dẫn và ngữ cảnh cho LLM bằng cách sử dụng PromptTemplate. Bước này nghe có vẻ tuần tự và cần gộp 2 hàm với nhau, vì vậy ta sử dụng RunnableSequence.
3. Bây giờ, chúng ta muốn kết hợp cả bước 1 và 2 để nhận được hai đầu ra riêng biệt: một cho cảm xúc và một cho bản tóm tắt của mô hình. Bước này cần gộp các Runnable lại với nhau, nên mình sẽ sử dụng RunnableMap.

```

1 from langchain.prompts import PromptTemplate
2 from langchain.llms import OpenAI
3 from langchain.schema.runnable import Runnable, RunnableSequence, RunnableMap,
  RunnableLambda
4
5 # Định nghĩa các Runnables riêng lẻ
6 sentiment_analysis_runnable = RunnableLambda(lambda text: "Positive" if "good" in
  text.lower() else "Negative")
7
8 # Sử dụng OpenAI làm LLM ví dụ (cần cài đặt và cấu hình khóa API)
9 llm = OpenAI(openai_api_key="YOUR_OPENAI_API_KEY")
10
11 summarization_runnable = PromptTemplate(input_variables=["text"], template="Tóm tắt
  đoạn văn này: {text}") | llm # | đại diện cho RunnableSequence
12
13 # Kết hợp các Runnables thành một chuỗi (pipeline)
14 pipeline = RunnableMap({
15     "sentiment": sentiment_analysis_runnable,
16     "summary": summarization_runnable
17 })
18
19 # Gọi pipeline
20 feedback = "Ánh xạ sản phẩm rất tốt và vượt quá mong đợi."
21 result = pipeline.invoke(feedback)
22
23 print(result)
24 # Output (có thể khác tùy thuộc vào LLM):
25 # {
26 #     "sentiment": "Positive",
27 #     "summary": "Ánh xạ sản phẩm xuất sắc."
28 # }
29

```

Listing 6: Ví dụ về quy trình làm việc kết hợp các Runnable

Demo kết quả mô hình RAG cơ bản

Quy trình thực hiện

Ví dụ Code Snippet (Minh họa)

Kết quả minh họa

Cải Thiện Mô hình RAG

1 Prompting có cấu trúc (Structured Prompting)

2 Các kiểu Prompt khác nhau

3 Cải tiến tốc độ truy vấn sử dụng FAISS

Lợi ích khi sử dụng FAISS:

Cách tích hợp FAISS với LangChain:

Tổng kết

Kết Thúc

Phụ lục giải thích thuật ngữ

- **Embedding (Nhúng):** Để thể hiện ngữ nghĩa của 1 từ 1 cách chính xác nhất, Embedding được sử dụng để chuyển đổi dữ liệu (thường là văn bản) thành các vector đa chiều, giúp máy tính hiểu và xử lý ngữ nghĩa của dữ liệu đó. Mục tiêu là tạo ra các vector sao cho các đối tượng có ý nghĩa tương tự sẽ gần nhau trong không gian vector.
- **Parse (Phân tích cú pháp):**

Trong lập trình và xử lý dữ liệu, "parse" là quá trình **chuyển đổi một dạng dữ liệu** (thường là một chuỗi văn bản, số, hoặc bất kỳ loại dữ liệu thô nào) **thành một cấu trúc dữ liệu có ý nghĩa**.

- Ví dụ: Khi một chương trình "parse" một chuỗi văn bản, nó sẽ phân tích và chia nhỏ chuỗi đó thành các phần nhỏ hơn, có ý nghĩa (gọi là "tokens") dựa trên một tập hợp các quy tắc (ngữ pháp). Mục đích là để máy tính có thể hiểu và làm việc với dữ liệu đó dễ dàng hơn.
- Minh họa: Hãy xem xét biểu thức toán học " $4+10$ ". Đối với máy tính, đây chỉ là các ký tự riêng lẻ '4', '+', '1', '0'. Để thực hiện phép tính, máy tính phải "parse" biểu thức này. Một chương trình phân tích cú pháp sẽ nhận diện '+' là phép cộng, và từ đó biết rằng các ký tự đứng trước và sau nó là các chữ số biểu thị hai số cần cộng. Nó sẽ tạo ra một cấu trúc mới để biểu diễn thông tin này một cách tốt hơn cho phần tiếp theo của chương trình, ví dụ như chuyển "4" thành số nhị phân 100 và "10" thành 1010, và biểu thức " $4+10$ " thành một dạng dễ hiểu hơn cho máy tính như: 'ADD 100 1010'.

1

- **Protocol (Giao thức):**

Là một tập hợp các quy tắc, định dạng và quy trình chuẩn mực **quy định cách dữ liệu được truyền tải và nhận giữa các thiết bị hoặc chương trình** trong một mạng. Giao thức đảm bảo rằng các bên tham gia có thể giao tiếp một cách hiệu quả và hiểu được thông điệp của nhau.

- **Synchronous (Đồng bộ) và Asynchronous (Bất đồng bộ):**

Đây là hai khái niệm thường gây nhầm lẫn vì chúng liên quan đến **thời gian thực hiện đồng thời** chứ không nhất thiết là luồng thực thi trong lập trình. Để dễ hiểu hơn, mình sẽ so sánh 2 khái niệm Lập trình Đồng bộ và Bất Đồng bộ:

- **Lập trình Đồng bộ (Synchronous Programming - "Từng tác vụ")**: Trong ngữ cảnh lập trình, **việc bắt đầu của một tác vụ được đồng bộ hóa với việc hoàn thành của tác vụ trước đó**. Nghĩa là các tác vụ thực thi nối tiếp nhau, **tác vụ 1 xong thì tác vụ 2 mới bắt đầu**
- **Lập trình Bất đồng bộ (Asynchronous Programming - "Đồng thời các tác vụ")**: Trong ngữ cảnh lập trình, **việc bắt đầu của một tác vụ không được đồng bộ hóa với việc hoàn thành của một tác vụ khác**. Nghĩa là chúng có thể chồng lấn trong quá trình thực thi, **tác vụ 1 hoạt động song song với tác vụ 2**.
 - * Các hoạt động trong lập trình bất đồng bộ **cho phép một chương trình tiếp tục thực thi 1 hoặc nhiều tác vụ trong khi chờ đợi một tác vụ khác hoàn thành** (thường là các hoạt động tốn nhiều thời gian) mà không chặn luồng chính.
 - * Lưu ý rằng khi chạy bất đồng bộ trên một luồng đơn (single thread), đó chỉ là việc 1 luồng chuyển đổi nhanh chóng giữa các tác vụ khác nhau, tạo ra ảo giác về nó đang xử lý song song.
 - * Lợi ích của lập trình bất đồng bộ thường được nhận thấy rõ rệt nhất trong Giao diện người dùng (User Interface - UI), nó giúp UI không bị "đóng băng" khi một hoạt động nặng đang chạy ngầm.

– **LangChain Expression Language (LCEL)**

LangChain Expression Language (LCEL) là một cú pháp được tạo ra để giúp chạy các chuỗi (chains) một cách tối ưu, dù là đồng bộ (song song) hay bất đồng bộ (không song song), bằng cách kết hợp các Runnable với nhau. LCEL rất phù hợp cho các chuỗi đơn giản (ví dụ: prompt + llm + parser). Tuy nhiên, LangGraph được khuyến nghị để mở rộng thêm khi Ta xây dựng các chuỗi phức tạp hơn (ví dụ: có phân nhánh, vòng lặp, nhiều tác nhân, v.v.). Lưu ý rằng LCEL vẫn có thể được sử dụng trong LangGraph.